2026.02.25

김태훈

LLM Reply Improvement

RAG LLM 답변 길이 문제 해결 방안

목차

01 프로젝트 설명

AS-IS: RAG 기반 요약 구조의 한계

현재 방식

- RAG(Retrieval-Augmented Generation) 기반 문서 요약 수행
- LLM 출력 길이 제한으로 긴 문서를 한 번에 요약 불가
- 문서 분할 후 반복 요약 방식 적용
  - ex.) 16장 길이의 에세이를 8장으로 요약해줘 → 답변: 1장 이내의 요약본
  - 전체 요약 생성을 위해 최소 n회 반복 수행

주요 문제

- 반복 호출로 인한 운영 비효율 증가
- 정보 손실 리스크
- 전체 맥락 단절 가능성

02 아키텍처 및 작동 원리

TO-BE: Plan-and-Execute: 목차 생성 이후 개별적인 RAG 실행

Self-Planning 기반 지능형 RAG 워크플로우:

Step 1. [Intent Analysis]:

- 사용자 질의의 의도와 형식을 분석하여 최적화된 리포트 구조(Plan) 설계 (Non-RAG 기반 추론)

Step 2. [Adaptive Planning]:

- 생성된 목차별 세부 주제 분할 및 각 섹션에 최적화된 검색 쿼리 생성

Step 3. [Iterative RAG Retrieval]:

- 각 목차별 독립적인 RAG 프로세스 가동을 통해 정보 밀도와 정확도 극대화

Step 4. [Contextual Synthesis]:

- 분산 생성된 콘텐츠를 통합하여 일관성 있는 최종 리포트 완성

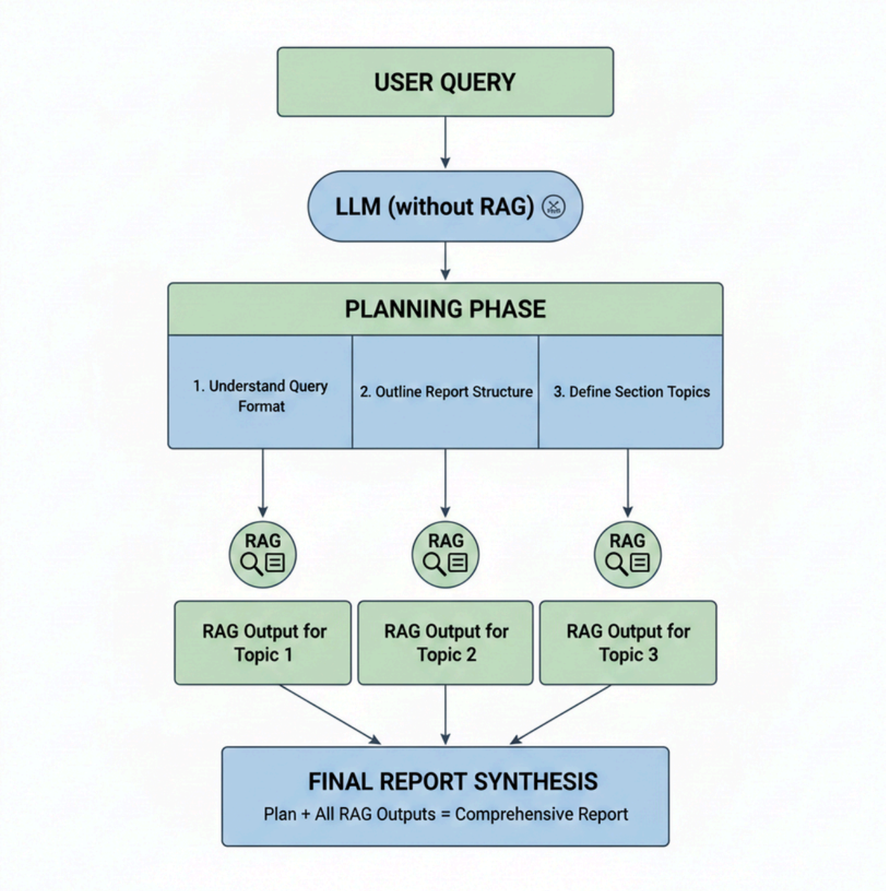

03 코드 구현

https://github.com/KimHoon98/RAG-Implementation/tree/main/3.)%20PDF%20RAG%20(LLM%20%2B%20improvement)%20implementation

04 개선 방향

RAG Document 인증 / 연관성 확인

LangSmith Trace: 각 VectorStoreRetriever 함수는 8개의 Document를 Fetch하게 됩니다. 다만 이 8개의 모든 Document가 필요한 내용인지, 그리고 연관성이 있는지에 대해서 불확실합니다.

해결 방안:

- Advanced RAG deployment:
  - Advanced RAG의 첫부분: Document의 연관성 확인 및 Priority (우선 사항) 체크를 통해 필요한 Document (Splits)만 추출하도록 연결